



CNN

深度学习介绍

- 机器学习与深度学习的区别
 - 特征处理
 - 机器学习：手动完成
 - 深度学习：不需要人工处理，通过大量数据的训练自动得到模型
 - 图像（人脸身份认证、物体识别、场景识别）、自然语言处理（机器翻译、文本识别、聊天对话）、语音（语音识别）等难以进行特征提取的领域
 - 机器学习效果不佳/ 特征需要复杂处理的地方
- 深度学习代表算法 – **神经网络** Artificial Neural Network – ANN
 - 模仿生物神经网络结构和功能的计算模型
 - 包含：
 - 输入层
 - 隐藏层
 - 输出层



- 神经网络的特点
 - 每个连接都有权重，同一层神经元之间没有连接
 - 神经元当中会含有激活函数



神经网络基础

逻辑回归 – Logistic 回归

简介

Logistic Regression is a supervised learning algorithm used for classification. It predicts the probability that an input belongs to a specific class.

The following equation represents the linear component of a logistic regression model:

$$z = \underset{\text{bias}}{b} + w_1 x_1 + w_2 x_2 + \dots + w_N x_N$$

where:

- z is the output of the linear equation, also called the **log odds**.
- b is the bias.
- The w values are the model's learned weights.
- The x values are the feature values for a particular example.

它通过 Sigmoid 函数将线性组合映射为概率，常用于二分类问题（如是否患病、是否购买）。它的核心思想是：预测的是事件发生的概率，而不是连续值。

逻辑函数 (Sigmoid) 形式为

$$p = \frac{1}{1 + e^{-z}}, \quad z = \beta_0 + \beta_1 x_1 + \dots + \beta_n x_n$$


其中 p 是预测概率， z 是输入特征的线性组合。

- 若 $p \geq 0.5$ ，预测为类别 1；否则为类别 0。阈值可以根据实际情况调整。

Loss

- Linear regression module : **squared loss** (also called L_2 loss) $\rightarrow$ works well for a linear model where the **rate of change** of the output values is **constant**.
- The **sigmoid** curve is **s-shaped** rather than linear. When the **log-odds (z)** value is closer to 0, small increases in z result in much larger changes to y than when z is a large positive or negative number.

Sigmoid Function



input	logistic output	required digits of precision
5	0.993	3
6	0.997	3
7	0.999	3
8	0.9997	4
9	0.9999	4
10	0.99998	5

If you used squared loss to calculate errors for the sigmoid function, as the output got closer and closer to **0** and **1**, you would need **more memory to preserve the precision** needed to track these values.

为了在计算机中精确表示这些极小的梯度值，就需要更高的数值精度（更多的位数），否则会出现舍入误差

而且，用平方误差来衡量 Sigmoid 输出的误差，当预测概率接近 0 或 1 时，梯度会非常小（梯度消失）。这会导致优化过程变慢，甚至停滞。

Log Loss 的优势：避免梯度消失；强烈惩罚错误预测。

$$\text{Log Loss} = -\frac{1}{N} \sum_{i=1}^N y_i \log(y'_i) + (1 - y_i) \log(1 - y'_i)$$

where:

- N is the number of labeled examples in the dataset
- i is the index of an example in the dataset (e.g., (x_3, y_3) is the third example in the dataset)
- y_i is the label for the i th example. Since this is logistic regression, y_i must either be **0 or 1**.
- y'_i is your model's **prediction** for the i th example (somewhere between 0 and 1), given the set of features in x_i . **预测值 (0~1)**

真实标签: 0/1

$$\text{Cost}(p, y) = -y \cdot \log(p) - (1 - y) \cdot \log(1 - p)$$

- 当 $y = 1$: 损失 = $-\log(p)$.
 - 如果 p 接近 1, 损失趋近于 0。
 - 如果 p 很小 (比如 0.01), 损失非常大 (≈ 4.6), 强烈惩罚错误预测。
- 当 $y = 0$: 损失 = $-\log(1 - p)$.
 - 如果 p 接近 0, 损失趋近于 0。
 - 如果 p 接近 1, 损失非常大。


梯度下降算法

目标：使损失函数找到最小值

方式：梯度下降


- 函数的梯度（gradient）指出了函数的最陡增长方向。梯度方向走，函数增长得就越快。
- 按照梯度的负方向走，函数值自然就降低的最快了。

- 模型训练的目标是寻找合适的 w 与 b 以最小化代价函数值。



- 凸函数：不含多个局部最低

通过平面来理解梯度下降过程：



CNN 卷积神经网络 (Convolutional neural network)

Designed to process grid-like data such as images.

Input Layer	Receives raw image data (e.g., 32×32×3 for RGB).	输入层接收原始图像数据，保持空间结构。
Convolutional Layer	Applies filters (kernels) to extract features like edges and textures.	卷积层通过卷积核 提取局部特征 ，如边缘、纹理。
Activation Layer	Introduces non-linearity (ReLU, Tanh).	激活层引入 非线性 ，使模型能学习复杂模式。
Pooling Layer	Reduces spatial dimensions (Max Pooling, Average Pooling).	池化层 降低特征图尺寸 ，减少计算量并防止过拟合。
Flattening	Converts feature maps into a vector.	展平层 将多维特征图转为一维向量 。
Fully Connected Layer	Performs classification based on extracted features.	全连接层根据特征进行最终分类。

网络类型	求和公式	权重特点	适用场景
普通神经网络 (Fully Connected NN)	$z = \sum_i w_i x_i + b$	每个输入特征都有独立权重 w_i ，参数量大	结构化数据（表格、数值预测）
卷积神经网络 (CNN)	$z_j = \sum_{u,v} w_{u,v} \cdot x_{j+u,j+v} + b$	权重只作用在局部区域（卷积核），并在不同位置共享	图像、视频、语音等网格数据

1. 连接方式

- 普通神经网络：每个神经元与上一层所有输入相连 → 参数量随输入维度急剧增加。
- CNN：每个卷积核只与输入的一小块区域相连 → 参数量大幅减少。


2. 权重使用

- 普通神经网络：每个连接都有独立权重。
- CNN：同一个卷积核的权重在整个输入空间共享，保证模型能识别相同模式（如边缘）在不同位置出现。
 - 平移不变性 **translation invariance** 平移不影响当前特征


3. 求和内容

- 普通神经网络：对所有输入特征做加权求和。
- CNN：对局部区域做加权求和（卷积），再滑动窗口重复计算。

CNN 基础组件：




- 卷积层：提取图像中的局部特征 – 关键特征
- 池化层：降低特征的空间尺寸，减少计算量
- 全连接层：特征整合，映射到最终输出



卷积核 Convolution kernel 内的数值：权重（画在连线上同理）

Sliding property of convolution: In CNNs, a convolutional filter slides across the input matrix (image or feature map) 卷积核会在输入矩阵（图像或特征图）上逐步移动。At each position, it computes a weighted sum of the local region. This sliding allows the same filter to detect the same pattern (e.g., edges, textures) at different spatial locations.

- 但是存在问题：不均匀 --> 更加关心中心的内容 --> 被遍历更多次。
- Padding 解决 => 对于整体的关注程度相似




同时，只要 Convolutional kernel 的大小，大于 1*1，最后 feature map 的大小都会小于本身；

- Padding 解决 => 输入输出大小一致。

卷积处理多通道信息

先局部，再整体




1. **局部处理 (Local processing)**: 卷积核只处理输入的一小块区域 (例如 3×3 的局部区域)。
2. **跨通道加权求和 (Channel-wise summation)**: 对于多通道输入 (如 RGB), 卷积核在每个通道的局部区域分别加权求和。
3. **整体输出 (Global aggregation)** 把所有通道的结果相加, 得到该位置的一个整体输出值。
4. **滑动生成特征图 (Sliding to form feature map)**: 卷积核在输入上滑动, 重复上述过程, 形成完整的特征图。

卷积的设计原理

1. **参数量**
 - 为什么神经网络处理图片效果不好? --> 参数过多
 - CNN 相比全连接网络**大幅减少参数量**。它不是为每个像素都分配独立权重, 而是用小卷积核, 并在不同位置共享权重 Convolution uses small kernels with **shared weights**.
 - 连线数目由 convolution kernel 决定
2. **局部相关性 Local Correlation** 图像具有强烈的局部相关性——相邻像素之间存在联系。卷积通过处理局部区域来利用这一特性, 提取边缘、纹理和形状。
3. **人类的视觉习惯 Human Visual Habit**: 人类视觉也是先局部处理, 再整体整合。CNN 模仿这一习惯, 在浅层识别简单模式, 在深层识别复杂对象。

卷积的特征提取



在 CNN 中，“多层”是它最重要的设计思想之一。每一层都在不同层次上提取特征，逐步从简单到复杂。

This multi-layer hierarchy mimics human vision: local details first, then global understanding.

- 浅层特征 (Shallow features)

- Early convolutional layers capture low-level features such as edges, lines, and simple textures.
- 比如边缘、线条和简单纹理。

- 中层特征 (Intermediate features)

- Middle layers **combine** these simple features into more complex patterns, such as corners, shapes, or repeated textures. 中层卷积层把简单特征组合成更复杂的模式，比如角点、形状或重复纹理。

- 深层特征 (Deep features)

- Deeper layers capture high-level semantic features 高级语义特征, such as faces, objects, or categories.

在感受野一定的情况下，层数越多，每一层的输出就是上一层特征的组合。这样层层叠加，提取到的特征就更加丰富和显著。

- **感受野**：决定单个神经元能看到的输入范围。
- **多层结构**：在固定感受野下，后续层不是扩大范围，而是综合前层的特征。
- **结果**：多层让模型从简单特征逐步组合成复杂模式，即使感受野大小不变，特征表达也更强。

池化操作

池化 (Pooling) 是 CNN 中的重要操作，用来**缩小特征图的尺寸，同时保留主要信息**。它的核心思想是：在一个小区域内进行聚合（最大值或平均值），减少数据量但保留关键特征。

- Max Pooling

- 在局部区域取最大值，突出最显著的特征。

- **Average Pooling**

- 在局部区域取平均值，使特征更平滑。

作用

- Reduce computation and parameters
- Prevent overfitting
- Provide translation invariance 提供平移不变性（同一特征在不同位置仍能识别）

举例

- 输入特征图大小：4×4
 - 使用 2×2 的 Max Pooling → 每个区域取最大值 → 输出特征图大小变为 2×2。
-

BP